# Департамент образования и науки города Москвы

Государственное автономное образовательное учреждения высшего образования города Москвы «Московский городской педагогический университет»

Институт цифрового образования Департамент информатики, управления и технологий

## Лабораторная работа 1.

Установка и настройка распределенной системы. Простейшие операции и знакомство с функциональностью системы.

Выполнил студент группы АДЭУ-221 Джамалова Сабина Шахиновна Проверил доцент Босенко Тимур Муртазович

Москва

**Цель работы:** ознакомление с процессом установки и настройки распределенных систем, таких как Apache(Arenadata) Hadoop или Apache Spark. Изучить основные операции и функциональные возможности системы, что позволит понять принципы работы с данными и распределенными вычислениями.

#### Задание:

6. Выполнение задачи на агрегацию данных. Данные: Исторические данные по акциям Норильского никеля (GMKN) с сайта Московской биржи (moex.com)

#### Выполнение:

#### **Apache Spark**

#### 1. Загрузка данных:

#### 2. Перенос в каталог:

```
hadoop@devopsvm:~$ hdfs dfs -mkdir /user/hadoop/spark_data
2024-10-19 00:03:43,692 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platf
orm... using builtin-java classes where applicable
hadoop@devopsvm:~$ hdfs dfs -put AAPL.csv /user/hadoop/spark_data
2024-10-19 00:03:53,210 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platf
orm... using builtin-java classes where applicable
hadoop@devopsvm:~$
```

# 3. Запуск Spark и выполнение простейших операций:

```
hadoop@devopsvm:~$ pyspark
Python 3.12.3 (main, Jul 31 2024, 17:43:48) [GCC 13.2.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
24/10/18 23:51:51 WARN Utils: Your hostname, devopsvm resolves to a loopback address: 127.0.1.1; using
172.20.10.3 instead (on interface enp0s3)
24/10/18 23:51:51 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
24/10/18 23:51:56 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... usin
g builtin-java classes where applicable
Welcome to
   / _/___/ /___/ /___/
_\ \/ _ // _, // _/ /__/ version 3.4.3
Using Python version 3.12.3 (main, Jul 31 2024 17:43:48)
Spark context Web UI available at http://172.20.10.3:4040
Spark context available as 'sc' (master = local[*], app id = local-1729284718110).
.
SparkSession available as 'spark'.
```

#### 4. Загрузка данных:

df = spark.read.csv("file:///home/username/spark\_data/AAPL.csv", header=True, inferSchema=True)

## df.show(5)

#### 5. Подсчет количества строк:

```
print("Количество строк:", df.count())
```

```
>>> print("Количество строк:", df.count())
Количество строк: 11017
```

#### 6. Вывод схемы данных:

#### df.printSchema()

```
>>> df.printSchema()
root
|-- Date: date (nullable = true)
|-- Open: double (nullable = true)
|-- High: double (nullable = true)
|-- Low: double (nullable = true)
|-- Close: double (nullable = true)
|-- Adj Close: double (nullable = true)
|-- Volume: long (nullable = true)
```

#### 7. Базовая статистика:

#### df.describe().show()

```
8. Фильтрация данных:
```

```
df_filtered = df.filter(df["Date"] >= "2020-01-01")
df_filtered.show(5)
```

#### 9. Группировка и агрегация:

```
from pyspark.sql.functions import year, avg
```

```
df_yearly = df.withColumn("Year",
```

 $year(df["Date"])).groupBy("Year").agg(avg("Close").alias("Avg\_Close"))$ 

df yearly.orderBy("Year").show()

```
>>> from pyspark.sql.functions import year, avg
>>> df_yearly = df.withColumn("Year", year(df["Date"])).groupBy("Year").agg(avg("Close").alias("Avg_Close")
>>> df_yearly.orderBy("Year").show()
              Avg_Close|
lYearl
|1980|0.13590307692307693|
| 1981 | 0.10854781818181822 |
|1982|0.08545888142292486|
|1983| 0.1672740118577075|
|1984| 0.1196512490118577|
|1985|0.09023348809523808|
|1986|0.14491285375494065|
|1987| 0.3477511106719368|
|1988| 0.3708842411067196|
|1989| 0.3719529682539681|
|1990|0.33537290513834017|
|1991|0.46870147826086955|
|1992| 0.4893094763779526|
|1993|0.36630964426877505|
|1994| 0.3042905634920634|
|1995|0.36196595238095214|
11996 | 0.22249534645669278 |
|1997| 0.1604176679841897|
|1998| 0.2729004801587301|
|1999| 0.515805492063492|
+---+
only showing top 20 rows
```

10. Создание временного представления и выполнение SQL-запроса:

df.createOrReplaceTempView("stock\_data")

spark.sql("SELECT Year(Date) as Year, AVG(Close) as Avg\_Close FROM stock\_data GROUP BY Year(Date) ORDER BY Year").show()

```
>>> df.createOrReplaceTempView("stock_data")
>>> spark.sql("SELECT Year(Date) as Year, AVG(Close) as Avg_Close FROM stock_data GROUP BY Year(Date) ORDER BY
|Year| Avg_Close|
+----+------
|1980|0.13590307692307693|
|1981|0.10854781818181822|
|1982|0.08545888142292486|
|1983| 0.1672740118577075|
|1984| 0.1196512490118577|
|1985|0.09023348809523808|
|1986|0.14491285375494065|
|1987| 0.3477511106719368|
|1988| 0.3708842411067196|
|1989| 0.3719529682539681|
|1990|0.33537290513834017|
|1991|0.46870147826086955|
|1992| 0.4893094763779526|
|1993|0.36630964426877505|
|1994| 0.3042905634920634|
|1995|0.36196595238095214|
|1996|0.22249534645669278|
|1997| 0.1604176679841897|
|1998| 0.2729004801587301|
|1999| 0.515805492063492|
+----+
only showing top 20 rows
```

## 11. Выход из Spark:

```
spark.stop()
exit()
>>>
>>> spark.stop()
>>> exit()
hadoop@devopsvm:~$
```

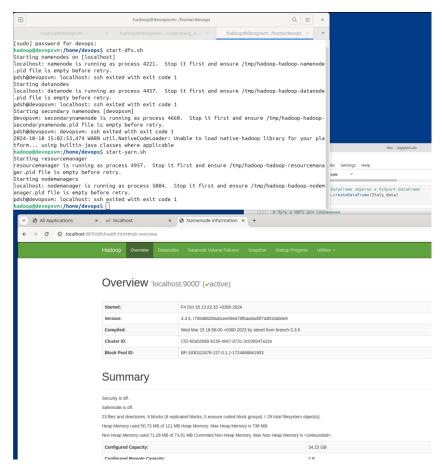
# Вариант 6.

1. Запуск Hadoop:

sudo su hadoop

start-dfs.sh

start-yarn.sh



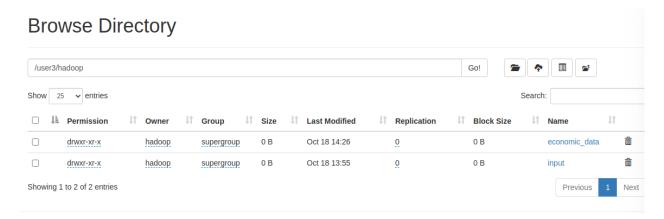
## 2. Проверка работы Hadoop:

jps

# hadoop@devopsvm:/home/devops\$ jps 8736 Jps 4660 SecondaryNameNode 4457 DataNode 5084 NodeManager 4957 ResourceManager 4221 NameNode hadoop@devopsvm:/home/devops\$

# 3. Проверка созданной директории:

http://localhost:9870



#### 4. Подготовка данных

```
<TICKER>, <PER>, <DATE>, <TIME>, <OPEN>, <HIGH>, <LOW>, <CLOSE>, <VOL>
GMKN,1,20200825,131300,19500.0000000,19500.0000000,19500.0000000,19500.0000000,1
GMKN,1,20200826,193400,20550.0000000,20550.0000000,20550.0000000,20550.0000000,1
GMKN,1,20200902,225600,20600.0000000,20600.0000000,20600.0000000,20600.0000000,4
GMKN,1,20200902,230500,20600.0000000,20600.0000000,20600.0000000,20600.0000000,10
GMKN,1,20200904,125700,21929.0000000,21929.0000000,21929.0000000,21929.0000000,1
GMKN,1,20200904,173000,21002.0000000,21003.0000000,19628.0000000,19628.0000000,4
GMKN,1,20200909,141600,19607,0000000,19607,0000000,19607,0000000,19607,0000000,1
GMKN,1,20200909,194400,21900.0000000,21900.0000000,21900.0000000,21900.0000000,1
GMKN,1,20200911,175100,19602.0000000,19602.0000000,19602.0000000,19602.0000000,1
GMKN,1,20200911,183500,21650.0000000,21650.0000000,21650.0000000,21650.0000000,1
GMKN,1,20200915,203600,19892.0000000,19892.0000000,19892.0000000,19892.0000000,2
GMKN,1,20200915,231800,20019.0000000,20019.0000000,20019.0000000,20019.0000000,4
GMKN,1,20200916,100700,19600.0000000,19600.0000000,19600.0000000,19600.0000000,1
GMKN,1,20200916,173000,19680.0000000,19680.0000000,19680.0000000,19680.0000000,3
GMKN.1.20200916.204800.19961.0000000.19961.0000000.19961.0000000.19961.0000000.1
GMKN,1,20200916,205800,19961.0000000,19961.0000000,19961.0000000,19961.0000000,2
GMKN,1,20200916,210300,19960.0000000,19960.0000000,19960.0000000,19960.0000000,1
GMKN,1,20200917,121900,19760.0000000,19760.0000000,19760.0000000,19760.0000000,1
GMKN.1.20200917.123400.19451.0000000.19451.0000000.19451.0000000.19451.0000000.1
GMKN,1,20200917,135600,19450.0000000,19450.0000000,19450.0000000,19450.0000000,2
GMKN,1,20200917,181100,19666.0000000,19666.0000000,19666.0000000,19666.0000000,1
GMKN,1,20200921,114800,19450.0000000,19450.0000000,19450.0000000,19450.0000000,3
GMKN,1,20200921,115400,19450.0000000,19450.0000000,19450.0000000,19450.0000000,6
GMKN,1,20200921,120000,19350.0000000,19350.0000000,19350.0000000,19350.0000000,2
GMKN,1,20200921,120100,19350.0000000,19350.0000000,19350.0000000,19350.0000000,1
GMKN,1,20200921,121700,19350.0000000,19350.0000000,19350.0000000,19350.0000000,3
GMKN,1,20200921,123300,19350.0000000,19350.0000000,19350.0000000,19350.0000000,1
GMKN,1,20200921,124100,19694.0000000,19694.0000000,19694.0000000,19694.0000000,1
GMKN,1,20200921,125700,19694,0000000,19694,0000000,19694,0000000,19694,0000000,1
GMKN,1,20200921,133500,19350.0000000,19350.0000000,19350.00000000,19350.00000000,2
GMKN,1,20200921,133600,19350.0000000,19350.0000000,19350.0000000,19350.0000000,1
GMKN,1,20200921,134000,19200.0000000,19200.0000000,19200.0000000,19200.0000000,1
GMKN,1,20200921,152300,19255.0000000,19255.0000000,19255.0000000,19255.0000000,1
GMKN,1,20200921,155600,19255.0000000,19255.0000000,19255.0000000,19255.0000000,1
GMKN,1,20200921,164800,19200.0000000,19200.0000000,19200.0000000,19200.0000000,1
GMKN,1,20200921,173900,19200.0000000,19200.0000000,19200.0000000,19200.0000000,1
GMKN,1,20200921,175700,19004.0000000,19051.0000000,19004.0000000,19051.0000000,20
```

#### 5. Загрузка данных:

#### wget

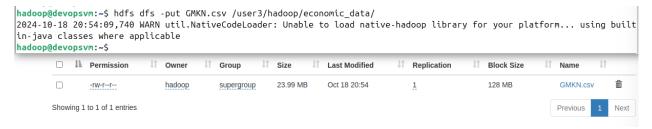
https://raw.githubusercontent.com/dzhamalovas/DS/refs/heads/main/GMKN.csv

## Проверка загрузки:

```
hadoop@devopsvm:~$ ls
GDP.csv GMKN.csv <mark>hadoop-3.3.5.tar.gz hdfs output snap spark-3.4.3-bin-hadoop3.tgz
hadoop@devopsvm:~$</mark>
```

#### 6. Загрузка данных в HDFS:

## hdfs dfs -put GMKN.csv /user3/hadoop/economic\_data/



## 7. Запуск Spark:

#### spark-shell

```
hadoop@devopsvm:~$ spark-shell
24/10/18 21:02:54 WARN Utils: Your hostname, devopsym resolves to a loopback address: 127.0.1.1; using 172.20.10.3
instead (on interface enp0s3)
24/10/18 21:02:54 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
24/10/18 21:02:59 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-j
ava classes where applicable
Spark context Web UI available at http://172.20.10.3:4040
Spark context available as 'sc' (master = local[*], app id = local-1729274580507).
Spark session available as 'spark'.
Welcome to
Using Scala version 2.12.17 (OpenJDK 64-Bit Server VM, Java 11.0.24)
Type in expressions to have them evaluated.
Type :help for more information.
scala>
```

# 8. Загрузка данных и просмотр основной информацции:

```
val data =
spark.read.option("header","true").csv("file:///home/hadoop/GMKN.csv")
```

## Работа Spark:

#### ▼ Event Timeline

Enable zooming



# 9. Вычисление агрегации данных:

#### Добавим столбцы для года и месяца на основе столбца <DATE>

```
scala> val dataWithYear = data.withColumn("Year", year(to_date(col("<DATE>"), "yyyyMMdd")))
dataWithYear: org.apache.spark.sql.DataFrame = [<TICKER>: string, <PER>: string ... 8 more fields]
scala> val dataWithYearAndMonth = dataWithYear.withColumn("Month", month(to_date(col("<DATE>"), "yyyyMMdd")))
dataWithYearAndMonth: org.apache.spark.sql.DataFrame = [<TICKER>: string, <PER>: string ... 9 more fields]
scala>
```

## Приведение типов к числовым для корректной агрегации

```
val numericData = data.withColumn("<CLOSE>",
col("<CLOSE>").cast("double"))
```

```
.withColumn("<HIGH>", col("<HIGH>").cast("double"))
.withColumn("<LOW>", col("<LOW>").cast("double"))
.withColumn("<VOL>", col("<VOL>").cast("long"))
```

```
numericData: org.apache.spark.sql.DataFrame = [<TICKER>: string, <PER>: string ... 7 more fields]
                      .withColumn("<HIGH>", col("<HIGH>").cast("double"))
res18: org.apache.spark.sql.DataFrame = [<TICKER>: string, <PER>: string ... 7 more fields]
                      .withColumn("<LOW>", col("<LOW>").cast("double"))
scala>
res19: org.apache.spark.sql.DataFrame = [<TICKER>: string, <PER>: string ... 7 more fields]
                      .withColumn("<VOL>", col("<VOL>").cast("long"))
scala>
Агрегация данных
val aggregatedResults = numericData.agg(
 avg("<CLOSE>").alias("Avg Close Price"),
 max("<HIGH>").alias("Max High Price"),
 min("<LOW>").alias("Min Low Price"),
 sum("<VOL>").alias("Total Volume")
scala> val aggregatedResults = numericData.agg(
| avg("<CLOSE>").alias("Avg_Close_Price"),
     max("<HIGH>").alias("Max_High_Price"),
     min("<LOW>").alias("Min_Low_Price"),
     sum("<VOL>").alias("Total_Volume")
aggregatedResults: org.apache.spark.sql.DataFrame = [Avg_Close_Price: double, Max_High_Price: string ... 2 more fields]
Вывод результатов:
scala> aggregatedResults.show()
       -----
    Avg_Close_Price|Max_High_Price|Min_Low_Price|Total_Volume|
+----+
|21511.068570376072| 28500.0000000|11640.0000000| 1.3570056E7|
+----+
Сохранение результатов в CSV файл:
aggregatedResults.write
 .option("header", "true")
 .csv("/home/hadoop/output/aggregated results.csv")
hadoop@devopsvm:~$ cd output
hadoop@devopsvm:~/output$ ls
aggregated_results.csv avg_GDR.csv
hadoop@devopsvm:~/output$
10. Выход из Spark.
scala> :q
hadoop@devopsvm:~$
```

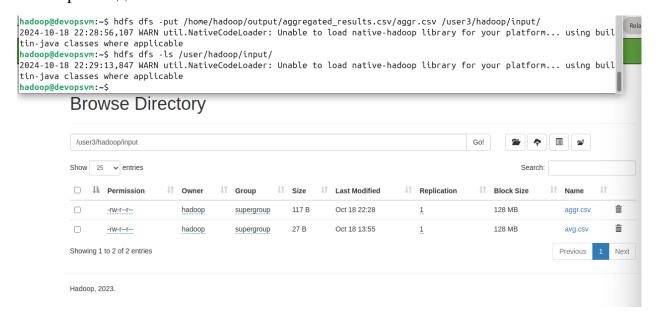
scala> val numericData = data.withColumn("<CLOSE>", col("<CLOSE>").cast("double"))

#### 11. Переименовываем файл:

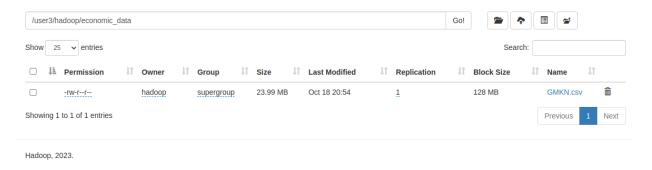
mv part-00000-\*.csv aggr.csv

hadoop@devopsvm:~/output/aggregated\_results.csv\$ ls
aggr.csv \_SUCCESS
hadoop@devopsvm:~/output/aggregated results.csv\$

## 12. Перенос данных в HDFS:



#### 13. Путь economic data:



#### 14. Остановка Hadoop в Ubuntu:

## stop-yarn.sh

hadoop@devopsvm:~\$ stop-yarn.sh
Stopping nodemanagers
Stopping resourcemanager
hadoop@devopsvm:~\$

stop-dfs.sh

```
hadoop@devopsvm:~$ stop-dfs.sh
Stopping namenodes on [localhost]
Stopping datanodes
Stopping secondary namenodes [devopsvm]
2024-10-18 22:45:44,877 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using buil
tin-java classes where applicable
```

#### stop-all.sh

```
hadoop@devopsvm:~$ stop-all.sh
WARNING: Stopping all Apache Hadoop daemons as hadoop in 10 seconds.
WARNING: Use CTRL-C to abort.
Stopping namenodes on [localhost]
Stopping datanodes
Stopping secondary namenodes [devopsvm]
2024-10-18 22:46:24,037 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using buil tin-java classes where applicable
Stopping nodemanagers
Stopping resourcemanager
```

#### Работа в Jupyter:

#### Установка необходимых библиотек:

```
[]: !pip install pyspark

Requirement already satisfied: pyspark in /home/devops/.config/jupyterlab-desktop/jlab_server/lib/python3.12/site-packages (3.5.3)

Requirement already satisfied: py4j==0.10.9.7 in /home/devops/.config/jupyterlab-desktop/jlab_server/lib/python3.12/site-packages (from pyspark) (0.10.9.7)

[2]: import pandas as pd import matplotlib.pyplot as plt
```

#### Создание сессии и чтение данных:

GMKN 1 20200902 234200 20600.0 20600.0 20600.0 20600.0

```
[3]: from pyspark.sql import SparkSession
        spark = SparkSession.builder
             .appName("Economic Data Analysis") \
.config("spark.hadoop.fs.defaultFS", "hdfs://localhost:9000") \
              .config("spark.ui.port", "4050") \
              .getOrCreate()
        # Установка количества разделов для shuffle операций spark.conf.set("spark.sql.shuffle.partitions", "50")
        24/10/18 23:08:20 WARN Utils: Your hostname, devopsvm resolves to a loopback address: 127.0.1.1; using 172.20.10.3 instead (on interface enp0s3) 24/10/18 23:08:20 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address Setting default log level to "MARN".

To adjust logging level use sc. settoglevel(newLevel). For SparkR, use setLogLevel(newLevel).

24/10/18 23:08:24 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
        # Tremme Hammax M3 TUTS
file_path = "hdfs://localhost:9000/user3/hadoop/economic_data/GMKN.csv"
df = spark.read.csv(file_path, header=True, inferSchema=True)
        # Просмотр первых строк данных
        df.show(5)
         |<TICKER>|<PER>| <DATE>|<TIME>| <OPEN>| <HIGH>| <LOW>|<CLOSE>|<VOL>|
            GMKN| 1|20200825|131300|19500.0|19500.0|19500.0|
                            1|20200826|193400|20550.0|20550.0|20550.0|20550.0|
1|20200902|225600|20600.0|20600.0|20600.0|
               GMKN
                            1|20200902|230500|20600.0|20600.0|20600.0|20600.0|
                        1|20200902|2334200|20600.0|20600.0|20600.0|20600.0|
         only showing top 5 rows
[9]: pandas_df = df.toPandas()
pandas_df.head()
         <TICKER> <PER> <DATE> <TIME> <OPEN> <HIGH> <LOW> <CLOSE> <VOL>
       0
              GMKN
                             1 20200825 131300 19500.0 19500.0 19500.0 19500.0
       1 GMKN 1 20200826 193400 20550.0 20550.0 20550.0 20550.0
       2
             GMKN 1 20200902 225600 20600.0 20600.0 20600.0 20600.0
      3 GMKN 1 20200902 230500 20600.0 20600.0 20600.0 10
```

# Построение графика цен закрытий Норильского никеля:

```
pandas_df['<DATE>'] = pd.to_datetime(pandas_df['<DATE>'], format='%Y%m%d')

plt.figure(figsize=(12, 6))
plt.plot(pandas_df['<DATE>'], pandas_df['<CLOSE>'], label='Цена закрытия', color='blue')

# Настройка графика
plt.title('Цены закрытия акций Норильского никеля (GMKN)')
plt.xlabel('Дата')
plt.ylabel('Цена закрытия (руб.)')
plt.xticks(rotation=45)
plt.lepend()
plt.grid()

# Показать график
plt.tight_layout()
plt.show()
```



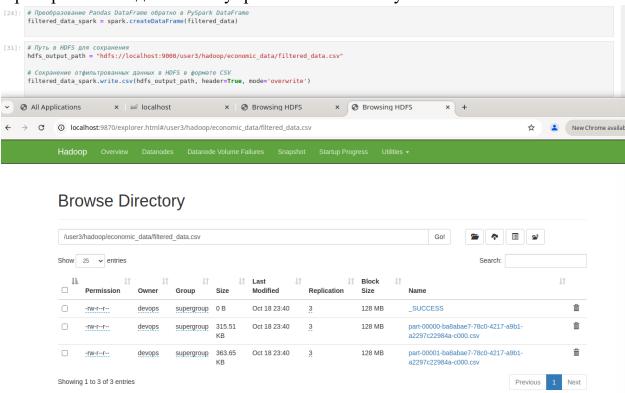
Посмотрим уникальные значения  $\langle PER \rangle$  и  $\langle VOL \rangle$ , а затем построим график при объеме торгов = 10

```
[17]; # Получение уникальных значений из столбца <PER> и <VOL> unique_per = pandas_df['<PER>'].unique() unique_vol = pandas_df['<VOL>'].unique()
        print("Уникальные значения <PER>:", unique_per) print("Уникальные значения <VOL>:", unique_vol)
         [22]: # Предположим, что мы выбрали уникальное значение объёма (например, 1)
         selected_volume = 10
        # Фильтрация данных по выбранному объему filtered_data = pandas_df[pandas_df['<VOL>'] == selected_volume]
        plt.figure(figsize=(12, 6))
plt.plot(filtered_data['<DATE>'], filtered_data['<CLOSE>'], label='Цена закрытия', color='blue')
        # Настройка графика
plt.title(f'Цены закрытия акций Норильского никеля (GMKN) при объеме торгов {selected_volume}')
plt.xlabel('Дата')
        plt.ylabel('Цена закрытия (руб.)')
plt.xticks(rotation=45) # Поворот дат для удобочитаемости
plt.legend()
plt.grid()
        # Показать график
plt.tight_layout()
plt.show()
                                                           Цены закрытия акций Норильского никеля (GMKN) при объеме торгов 10

Цена закрытия

            27500
             25000
         (b)
22500
             20000
         포
17500
            15000
             12500
```

## Преобразование данных в PySpark DataFrame и путь в HDFS:



#### Вывод:

Араche Spark — мощный инструмент для анализа больших объемов экономических данных благодаря высокой скорости и обработке данных в памяти. Он отлично подходит для итеративных задач, реального времени и машинного обучения. Наdoop эффективен для долговременного хранения данных и пакетной обработки, но медленнее из-за использования дискового хранилища.

Spark предпочтителен для анализа экономических данных в реальном времени, машинного обучения и больших вычислений, тогда как Наdoop больше подходит для хранения и обработки больших массивов данных на диске.